

Conception et Déploiement Cloud d'un MVP RAG

Architecture d'un moteur de recommandation d'événements culturels sous contraintes.

Auteur:	Samir Belasri
Projet:	RAG Events MVP
Formation:	Data Engineer OpenClassrooms
Date:	Mai 2026

Contexte & Besoin Métier : Franchir le mur sémantique


Limites Actuelles

Problème : La recherche classique par mots-clés échoue face aux requêtes nuancées.




Solution RAG

Solution : Le Retrieval-Augmented Generation comprend l'intention et contextualise la réponse.



Périmètre et Objectifs du MVP



Démarche Agile & Maîtrise des Risques

Must-Have (Focus MVP)

API FastAPI

Ingestion JSON

Pipeline RAG (Mistral)

Dockerisation

Déploiement AWS

Nice-to-Have (Évolutions)

Base vectorielle
managée

Interface Frontend

CI/CD Automatisée

Matrice des Risques

Risque :
Dépendances ML
lourdes

Mitigation : Version
"Cloud-Light" allégée.


Risque : Coûts
AWS imprévus

Mitigation : Alertes
budget & arrêt
manuel de l'instance.

Risque :
Hallucinations LLM

Mitigation : Prompt
engineering strict
limité au contexte.

Architecture Technique Globale



[Python] [FastAPI] [Docker] [AWS] [Mistral]

Le Pipeline de Données (Flux RAG)

POST /rag/build-index


Phase 1 : Ingestion

POST /rag/search

Phase 2 : Récupération

POST /rag/answer

Phase 3 : Génération



L'Arbitrage Décisif : Local vs Cloud-Light

 Architecture Locale Complète
(Non Viable sur AWS Free Tier)

Stack:

Torch, Sentence Transformers,
FAISS lourds.

Blocage:

Crash Docker sur EC2 t2.micro
par manque de RAM et stockage.

 Architecture Cloud-Light
(Déployée)

Stack:

Approche allégée basée sur NumPy
pour l'indexation vectorielle.

Résultat:

Réduction drastique du poids.
MVP 100% fonctionnel à coût nul.

Conclusion : L'ingénierie sous contrainte. L'adaptation garantit le succès
du déploiement cloud.

Déploiement Cloud : Provisionnement de l'instance AWS

Instance :	t2.micro (eu-west-3 / Paris) en exécution.
Environnement :	Amazon Linux 2023.
Réseau :	Déployé dans un VPC. Port 8000 ouvert temporairement.

The screenshot shows the AWS Management Console for an EC2 instance. The instance is named 'p13-rag-server' and has the ID 'i-0c6f2453593615987'. It is running in the 'eu-west-3' region. The instance type is 't2.micro'. The console shows various details including the public IP address (12.38.44.16), private IP address (172.31.44.225), and the DNS public address (ec2-12-28-84-16.eu-west-3.compute.amazonaws.com). The instance is in the 'En cours d'exécution' (Running) state.

```
ec2-user@13.38.84.16 ~ ssh - ssh
ED25519 key fingerprint is: SHA338:TyenRt1U57TujrSMtx6F2ngJLeD4/pDVTOLXHPK1982g
This key is not known by any other names.
Are you sure you want to continue connecting (yes/no/[fingerprint]) yes
Warning: Permanently added '13.38.84.16' (ED25519) to the list of known hosts.
** UARIS2N8: connection is using a post-quantum key exchange algorithm.
** This session may be vulnerable to "store now, decrypt later" attacks.
** This session may need to be upgraded. See https://openssh.com/pq.html

Amazon Linux 2023

https://aws.amazon.com/linux/amazon-linux-2023

[ec2-user@ip-172-31-33-229 ~]$ sudo dnf update -y
Amazon Linux 2023 Kernel Livepatch repository 255 kB/s | 38 kB 00:00
Dependencies resolved.
Nothing to do.
Complete!
[ec2-user@ip-172-31-34-229 ~]$
```


Conteneurisation Docker : Isolation et Reproductibilité

Bénéfices de l'approche :

- Installation validée du démon Docker sur AWS.
- Exécution isolée : le conteneur expose l'API sur le port 8000.
- Zéro syndrome 'ça marche sur ma machine' : déploiement standardisé.


```
[ec2-user@ip-172-31-43-229 ~]$ sudo installation
Created symlink /etc/systemd/system/multi-user.target.wants/docker.service -> /usr/lib/s
ystemd/system/docker.service.
[ec2-user@ip-172-31-43-229 ~]$
[ec2-user@ip-172-31-43-229 ~]$ sudo systemctl start docker
[ec2-user@ip-172-31-43-229 ~]$ sudo systemctl enable docker
Created symlink /etc/systemd/system/multi-user.target.wants/docker.service -> /usr/lib/
systemd/system/docker.service.
[ec2-user@ip-172-31-43-229 ~]$
```

```
[ec2-user@ip-172-31-43-229 ~]$ docker ps
CONTAINER ID   IMAGE          COMMAND                  CREATED        STATUS        PORTS
e575533df22c   docker.exe    "Running"               2 days ago    Running      0.0.0.0:8000->8000/tcp
[ec2-user@ip-172-31-43-229 ~]$
```


Interface Swagger : Une API documentée et interactive


Point d'entrée principal du MVP :

- La documentation est auto-générée et accessible publiquement via l'endpoint /docs.
- Tous les endpoints du cycle de vie RAG ont été validés en environnement cloud.



Sécurité & Monitoring (Périmètre MVP)

Politique de Sécurité



Couche 3 : Application

Clé SSH stricte (chmod 400).

Couche 2 : Réseau

Règles "Mon IP" sur le Security Group.

Couche 1 : Cloud

Secrets et variables (".env") exclus du versioning.

Stratégie de Supervision

Logs Applicatifs

Suivi structuré via `logging.yaml`.

```
INFO: Application startup complete.
```

Disponibilité

Endpoint dédié.

```
GET /health : 200 OK
```

Note : Monitoring avancé (Prometheus/Grafana) réservé pour la V2.

Stratégie FinOps : Gouvernance et Contrôle des Coûts

Gestion Budgétaire

Logique MVP “Low-Cost”

- Utilisation exclusive d’outils Open Source.
- Exploitation stricte de l’instance AWS Free Tier (t2.micro).

Gouvernance & Opérations (Objectif Zéro Coût)

Alertes : →

Configuration d’alertes de budget AWS.

Action : →

Arrêt manuel systématique de l’instance EC2 après chaque session.

Trade-off : →

Absence de Haute Disponibilité (SLA) assumée à ce stade.

Bilan du Déploiement : Objectifs Atteints

[OK]

Back-end : API FastAPI asynchrone, opérationnelle et documentée (Swagger).

[OK]

Cloud & Docker : Architecture conteneurisée et déployée avec succès sur AWS EC2.

[OK]


Data & IA : Pipeline RAG de bout-en-bout fonctionnel avec le LLM Mistral.

Portfolio GitHub

Conclusion : Transition réussie du POC expérimental vers une infrastructure MVP industrialisable.

[illegible]

Roadmap : Du MVP à la Production (V2)



Merci pour votre attention.

Je vous propose maintenant de passer à la session de questions-réponses ou à la démonstration de l'API.

Samir Belasri

Projet 13 - Data Engineer OpenClassrooms

Portfolio : github.com/SamB-DATA/portfolio-data-engineer

Code MVP : github.com/SamB-DATA/rag-events-mvp